Curso 2020-21
Práctica 4

# Práctica 4: Explotar el potencial de las arquitecturas modernas

NOTA: Leer detenidamente el enunciado de cada ejercicio antes de proceder a su realización.

El objetivo de esta práctica es experimentar y aprender a sacar partido a las arquitecturas multicore (o manycore) a través del framework de programación OpenMP [1].

Todo el trabajo asociado a esta práctica se realizará en entorno Linux. Para ello el estudiante puede emplear los ordenadores de los laboratorios, o bien el clúster de docencia de la asignatura. También será posible emplear un ordenador propio. En cualquiera de los casos, es necesarios comunicar en qué equipo/s se han desarrollado las pruebas.

#### MATERIAL DE PARTIDA

Junto con el enunciado de la práctica, se entrega un fichero, "MaterialP4.zip", que contiene los siguientes ficheros que serán referenciados a lo largo del enunciado:

- o omp1.c fichero con el código de ejemplo de un programa que crea hilos utilizando OpenMP. El número de hilos creados se pasa como argumento al programa.
- o omp2.c fichero con el código de ejemplo de un programa que muestras las diferencias en la declaración de la privacidad de variables en OpenMP.
- o pescalar serie.c-fichero con un código serie que realiza el producto escalar de dos vectores.
- o pescalar\_parl.c ficheros con el código de ejemplo de programas que realizan paralelización de bucles con OpenMP
- o Makefile fichero makefile utilizado para compilar todos los ficheros de código fuente. Debe ser modificado para que también se compilen los programas que se piden.
- o pi serie.c fichero con un código serie que realiza el cálculo de pi por integración numérica.
- o pi\_par1.c a pi\_par7.c ficheros con el código de variantes en OpenMP para calcular pi por integración numérica.
- o edgeDetector.c-programa que aplica un algoritmo de procesamiento de imágenes para detectar bordes.

#### **IMPORTANTE**

A lo largo de este documento se hará referencia a un número P que afectará a los experimentos y resultados que se obtendrán. El valor de P que debe utilizar debe ser igual al número de pareja módulo 8 más 1 (es decir será un número entre 1 y 8).



Curso 2020-21
Práctica 4

#### Ejercicio 0: información sobre la topología del sistema

En primer lugar, deberíamos de ser capaces de obtener la información relativa a la arquitectura de la máquina sobre la que estamos trabajando. Esto es sencillo en un sistema Linux y podemos hacerlo ejecutando cualquiera de los siguientes comandos:

- > cat /proc/cpuinfo
- > dmidecode

<u>NOTA:</u> este comando requiere permisos de superusuario, por lo que NO podremos utilizarlo en la instalación de los laboratorios. Puede utilizar en su lugar el comando Istopo. En el cluster está instalado en /share/apps/tools/hwloc/bin/lstopo

En particular, si nos fijamos en la información que nos da el fichero cpuinfo podemos deducir cuántos cores tiene nuestro equipo y si tiene o no habilitado la opción de hyperthreading (el parámetro cpu\_cores indica cuántas CPUs físicas hay en equipo en total, y el parámetro siblings hace referencia al número de CPUs virtuales). En un equipo con mas de un procesador, el parámetro physical\_id diferencia el procesador donde esta cada core.

A partir de la información expuesta, indique en la memoria asociada a la práctica los datos relativos a las cantidad y frecuencia de los procesadores disponibles en el equipo empleado, y a si la opción de *hyperthreading* está o no activa.

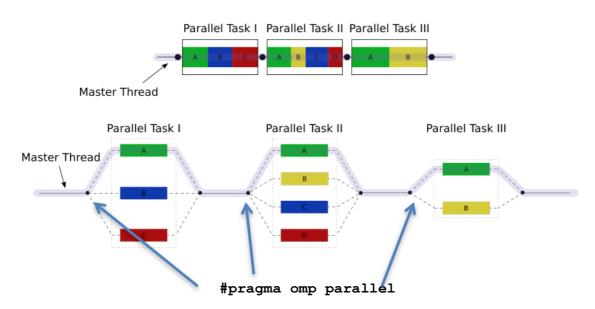
**Nota:** puede cambiar a diferentes nodos del cluster (desde el frontend) con ssh compute-x-y, para comprobar su arquitectura. Tenemos al menos nodos diferenciados para Intel (compute-0-0), nodos AMD (compute-0-7) con diferentes números de *cores*.

Curso 2020-21
Práctica 4

### Ejercicio 1: Programas básicos de OpenMP (1 p)

En este ejercicio, vamos a realizar una primera toma de contacto con programas basados en OpenMP. Para realizar la compilación de estos programas utilizaremos como compilador gcc, añadiendo las banderas – lgomp y –fopenmp para indicarle que queremos utilizar las librerías y extensiones de OpenMP.

OpenMP nos permite lanzar de una forma muy sencilla un número de hilos (o threads) para que lleven a cabo tareas de forma paralela (cada hilo ejecutando en su CPU correspondiente). La creación de un equipo de hilos se lleva a cabo cada vez que se incluye en la directiva #pragma omp parallel en el programa, y la sincronización y finalización de los hilos se realiza al terminar la región paralela señalada con el parallel.



En el material de partida, se pide compilar y ejecutar el programa omp1.c para comprobar cómo se lleva a cabo el lanzamiento de equipos de hilos, y familiarizarse con las funciones omp\_get\_num\_threads () y omp\_get\_thread\_num () que nos permiten identificar a cada uno de los threads en activo.

- 1.1 ¿Se pueden lanzar más threads que cores tenga el sistema? ¿Tiene sentido hacerlo?
- 1.2 ¿Cuántos threads debería utilizar en los ordenadores del laboratorio? ¿y en el clúster? ¿y en su propio equipo?

El número de threads que se lanza al abrir una región paralela se puede seleccionar de las siguiente maneras:

Con una variable de entorno:

```
OMP_NUM_THREADS

con una función:

omp_set_num_threads(int num_threads);

con una clausula dentro de la región paralela
```

#pragma omp parallel num\_threads(numthr)



Práctica 4

1.3 Modifique el programa omp1.c para utilizar las tres formas de elegir el número de threads y deduzca la prioridad entre ellas.

Una característica fundamental a la hora de programa utilizando OpenMP es definir correctamente qué variables han de ser públicas (accesibles a todos los hilos, es el valor por defecto) o privadas (cada hilo accede a su propia copia). Un ejemplo de la utilización de estas características puede encontrarse en el programa omp2.c.

Se pide ejecutar el programa omp2 e incluir la salida en la memoria de la práctica. En base a la salida obtenida (y tras leer y comprender el código fuente que la genera) conteste a las siguientes preguntas:

- ¿Cómo se comporta OpenMP cuando declaramos una variable privada?
- ¿Qué ocurre con el valor de una variable privada al comenzar a ejecutarse la región paralela?
- ¿Qué ocurre con el valor de una variable privada al finalizar la región paralela? 1.6
- ¿Ocurre lo mismo con las variables públicas?

Curso 2020-21
Práctica 4

### Ejercicio 2: Paralelizar el producto escalar (2 p)

Tomaremos como código de referencia el del producto escalar, cuya versión serie y un intento de código paralelizado se entregan como material de partida de la práctica. OpenMP está especialmente pensado para realizar la paralelización del trabajo de un bucle for entre los hilos del equipo. Cuando se quiere repartir el trabajo de un bucle de esta forma se utiliza la cláusula #pragma omp parallel for. Al indicar esta cláusula, OpenMP ya hace trabajo por nosotros como por ejemplo declarar como privada la variable que se utiliza como índice del bucle.

- 2.1 Ejecute la versión serie y entienda cual debe ser el resultado para diferentes tamaños de vector.
- 2.2 Ejecute el código paralelizado con el pragma openmp y conteste en la memoria a las siguientes preguntas:
  - ¿Es correcto el resultado?
  - ¿Qué puede estar pasando?

Antes de intentar reducir el tiempo de ejecución es imprescindible que el resultado sea correcto. Para ello debe garantizar que la acumulación que se utiliza en este código no tenga problemas por correra de datos.

2.3 Modifique el código anterior y denomine el programa pescalar\_par2. Esta versión deber dar el resultado correcto utilizando donde corresponda alguno de los siguientes pragmas

```
#pragma omp critical
#pragma omp atomic
```

- ¿Puede resolverse con ambas directivas? Indique las modificaciones realizadas en cada caso.
- ¿Cuál es la opción elegida y por qué?
- 2.4 Modifique el código anterior y denomine el programa resultante pescalar\_par3. Esta versión deber dar el resultado correcto utilizando donde corresponda alguno de los siguientes pragmas

```
#pragma omp parallel for reduction
```

Comparando con el punto anterior ¿Cuál será la opción elegida y por qué?



Curso 2020-21
Práctica 4

#### 2.6 Análisis de tiempos de ejecución.

Para realizar un análisis de tiempo de ejecución, elija un tamaño del vector que permita diferenciar el comportamiento de la paralelización.

Pruebe al menos 5 tamaños de vector diferentes y para elegirlos siga algún criterio razonable, por ejemplo, que el tiempo de ejecución del programa serie para el experimento de mayor tamaño se corresponda con 1 segundo y para el de menor tamaño sea de 0,01 segundo. Recuerde que para que las medidas tengan valor estadístico debe repetir cada medida al menos 5 veces evitando efectos indeseados como pueda ser la precarga de resultados.

Tomando ahora únicamente la ejecución de la versión serie y la versión paralela que considere que sea la mejor opción

- Se pide hacer un análisis del rendimiento obtenido en el problema del producto escalar para diferente número de hilos: de 1 a 2\*C, siendo C el número de cores del equipo empleado.
- Analice cómo varía la aceleración obtenida para vectores de diferentes tamaños.

La presentación de estos resultados se deberá incluir en la memoria de la práctica representando en una gráfica los tiempos de ejecución y en otra la aceleración obtenida en función del tamaño del vector. Teniendo en cuenta los resultados obtenidos, se pide contestar justificadamente las siguientes preguntas:

- En términos del tamaño de los vectores, ¿compensa siempre lanzar hilos para realizar el trabajo en paralelo, o hay casos en los que no?
- Si no compensara siempre, ¿en qué casos no compensa y por qué?
- ¿Se mejora siempre el rendimiento al aumentar el número de hilos a trabajar?
- Si no fuera así, ¿a qué debe este efecto?
- Valore si existe algún tamaño del vector a partir del cual el comportamiento de la aceleración va a ser muy diferente del obtenido en la gráfica.

Modifique el código de la versión paralela para que solo se ejecute en paralelo cuando el tamaño de vector sea lo suficientemente grande y justifique la ejecución en paralelo. Para ello utilice la clausula if(expression) dentro del pragma

#pragma omp parallel if (M>valor)

con la expresión adecuada para el tamaño de vector, M, que corresponda.

Curso 2020-21
Práctica 4

#### Ejercicio 3: Paralelizar la multiplicación de matrices (3 p)

Para este ejercicio se tomará como código de partida el de la multiplicación de matrices que cada alumno ha desarrollado a lo largo de la práctica 3 de la asignatura.

En este caso, el programa se compone de tres bucles anidados, por lo que a la hora de llevar a cabo la paralelización del trabajo a realizar es razonable preguntarse: ¿cuál de los bucles interesa paralelizar?

Se pide desarrollar y entregar (además de la versión serie de la práctica 3) tres versiones paralelas de la multiplicación de matrices paralelizando los tres bucles existentes. Las versiones entregadas han de funcionar de forma correcta.

Se pide rellenar las siguientes tablas realizando la ejecución para matrices de tamaño suficientemente grande para que los valores de tiempo de ejecución permitan ver diferencias entre los diferentes casos que se estudien (por ejemplo, empiece evaluando un tamaño de 1000x1000 que tarden unos 10 segundos y pruebe al menos otro tamaño que tarde 60 segundos):

Tiempos de ejecución (s)

Versión\# hilos	1	2	3	4
Serie				
Paralela – bucle1				
Paralela – bucle2				
Paralela – bucle3				

#### Speedup (tomando como referencia la versión serie)

Versión\# hilos	1	2	3	4
Serie	1			
Paralela – bucle1				
Paralela – bucle2				
Paralela – bucle3				

**NOTA:** se considera que el bucle 1 es el más interno, el bucle 2 es el bucle intermedio, y el bucle 3 es el bucle más externo. En el caso serie completar sólo la columna para un hilo.

Teniendo en cuenta los resultados obtenidos, conteste de manera razonada a las siguientes preguntas:

- 3.1 ¿Cuál de las tres versiones obtiene peor rendimiento? ¿A qué se debe? ¿Cuál de las tres versiones obtiene mejor rendimiento? ¿A qué se debe?
- 3.2 En base a los resultados, ¿cree que es preferible la paralelización de grano fino (bucle más interno) o de grano grueso (bucle más externo) en otros algoritmos?

Tomando como referencia los tiempos de ejecución de la versión serie y el de la mejor versión paralela obtenida anteriormente (la mejor combinación entre las tres versiones de código, y las C posibilidades para el número de hilos paralelos). Tome tiempos en un fichero y realice una gráfica de la evolución del tiempo de ejecución y la aceleración (de la versión paralela vs serie) al ir variando el tamaño de las matrices de NxN para N entre 512+P y 1024+512+P (con incrementos en N de 64). Tras incluir estas dos gráficas en la memoria, incluya un párrafo describiendo y justificando el comportamiento observado en las mismas.

3.3 Si en la gráfica anterior no obtuvo un comportamiento de la aceleración en función de N que se estabilice o decrezca al incrementar el tamaño de la matriz, siga incrementando el valor de N hasta conseguir una gráfica con este comportamiento e indique para que valor de N se empieza a ver el cambio de tendencia.



#### Ejercicio 4: Ejemplo de integración numérica (2 p)

El ejemplo con el que vamos a trabajar a lo largo de esta sesión consiste en obtener una aproximación del valor del número  $\pi$  mediante una integración numérica. En particular, vamos a calcular el área encerrada por una función f en el intervalo [0,1] aproximando dicha área mediante rectángulos con anchura igual a h y altura igual a f(x).

$$\int_{0}^{1} \frac{4}{1+x^{2}} dx = 4 \int_{0}^{1} \frac{1}{1+x^{2}} dx = 4 \left[ \tan^{-1}(1) - \tan^{-1}(0) \right] = 4 \left[ \frac{\pi}{4} - 0 \right] = \pi$$

Cuanto más estrechos sean estos rectángulos, mayor será la aproximación al resultado real y por tanto al número  $\pi$ . Un ejemplo de programa que realiza esta tarea puede encontrarse en el fichero pi\_serie.c que se encuentra en la carpeta de material de para la práctica.

<u>Pregunta 4.1:</u> ¿Cuántos rectángulos se utilizan en la versión del programa que se da para realizar la integración numérica?



Curso 2020-21
Práctica 4

## Perdida de rendimiento por el efecto de falso compartir (*False sharing*) en OpenMP

En el material de partida se encuentras varias versiones paralelas del algoritmo comentado anteriormente. Fíjese concretamente en las versiones pi\_par1.c y pi\_par4.c.

Pregunta 4.2: ¿Qué diferencias observa entre estas dos versiones?

**Ejercicio 4.3:** Ejecute las dos versiones recién mencionadas. ¿Se observan diferencias en el resultado obtenido? ¿Y en el rendimiento? Si la respuesta fuera afirmativa, ¿sabría justificar a qué se debe este efecto?

En los programas pi\_par2.c y pi\_par3.c se incorporan dos modificaciones distintas sobre la versión 1 para intentar obtener un rendimiento similar a la versión 4.

**Ejercicio 4.4:** Ejecute las versiones paralelas 2 y 3 del programa. ¿Qué ocurre con el resultado y el rendimiento obtenido? ¿Ha ocurrido lo que se esperaba?

<u>Ejercicio 4.5:</u> Abra el fichero pi\_par3.c y modifique la línea 32 del fichero para que tome los valores fijos 1, 2, 4, 6, 7, 8, 9, 10 y 12. Ejecute este programa para cada uno de estos valores. ¿Qué ocurre con el rendimiento que se observa?

En el fichero pi\_par5.c se encuentra una versión que intenta resolver el problema de la falsa compartición mediante el uso de variables privadas y la creación de una sección crítica.

**Ejercicio 4.6:** Ejecute las versiones 4 y 5 del programa. Explique el efecto de utilizar la directiva *critical*. ¿Qué diferencias de rendimiento se aprecian? ¿A qué se debe este efecto?

**Ejercicio 4.7:** Ejecute las versiones 6 y 7 del programa. Explique el efecto de utilizar las directivas utilizadas. ¿Qué diferencias de rendimiento se aprecian? ¿A qué se debe este efecto?



Curso 2020-21
Práctica 4

#### Ejercicio 5: Optimización de programas de cálculo (4 puntos)

Una de las ventajas de OpenMP es su extrema facilidad de aplicarse a programas de cálculo intensivo sin requerir un cambio completo de la arquitectura o el diseño de este. En este último ejercicio, se propone aplicar todos los conocimientos obtenidos durante la asignatura para optimizar y paralelizar un programa de propósito aplicado.

En el fichero edgeDetector.c se incluye un programa que aplica un algoritmo de procesamiento de imágenes para detectar bordes. Este algoritmo nos ha sido proporcionado, a modo de prueba de concepto, con la idea de que finalmente procese en tiempo real imágenes de un streaming de video. Para ello, se recuerda a los alumnos que un video suele estar compuesto de aproximadamente 30 fps (frames per second). Esto es, el programa tendría que procesar 30 imágenes en un segundo.

#### Responda razonadamente a las preguntas:

- 1. El programa incluye un bucle más externo que itera sobre los argumentos aplicando los algoritmos a cada uno de los argumentos (señalado como Bucle 0). ¿Es este bucle el óptimo para ser paralelizado?
  - a. ¿Qué sucede si se pasan menos argumentos que número de cores?
  - Suponga que va a procesar imágenes de un telescopio espacial que ocupan hasta 6GB cada una, ¿es la opción adecuada? Comente cuanta memoria consume cada hilo en función del tamaño en pixeles de la imagen de entrada
- 2. Durante la práctica anterior, observamos que el orden de acceso a los datos es importante. ¿Hay algún bucle que esté accediendo en un orden subóptimo a los datos? Corríjalo en tal caso.
  - a. Es imprescindible que el programa siga realizando el mismo algoritmo, por lo que solo se deberían realizar cambios en el programa que no cambien la salida.
  - b. Explique por qué el orden no es el correcto en caso de cambiarlo.
- 3. Obviando el Bucle 0, pruebe diferentes paralelizaciones con OpenMP comentando cuales deberían obtener mejor rendimiento.
  - a. Es imprescindible que el programa siga realizando el mismo algoritmo, por lo que solo se deberían realizar cambios en el programa que no cambien la salida.
  - b. No es necesaria la exploración completa de todas las posibles paralelizaciones, es necesario utilizar los conocimientos obtenidos en la práctica para acotar cuales serían las mejores soluciones. Los razonamientos que utilice deben ser incluidos en la memoria.
- 4. Rellene una tabla con resultados de tiempos y *speedup* respecto a la versión serie para imágenes de distintas resoluciones (SD, HD, FHD, UHD-4k, UHD-8k). Añada a su vez una columna que sea la tasa de fps a la que procesaría el programa.
- 5. Algo que hemos dejado de lado es utilizar las optimizaciones del compilador. Repita el apartado anterior añadiendo al comando gcc la bandera -O3. Investigue sobre las optimizaciones que implementa el compilador (y como podrían afectar a nuestra paralelización). ¿Implementa el desenrollado de bucles? ¿Está activada esta opción? ¿Implementa algún tipo de vectorización? **Nota**: la opción -O3 puede generar warnings al ser compilado. Compruebe que la salida sigue siendo la misma en todo caso.



Práctica 4

#### **MATERIAL A ENTREGAR**

Memoria con las respuestas a las preguntas a lo largo del enunciado.

En subdirectorios independientes, los ficheros con los datos obtenidos en los experimentos de los ejercicios que así lo indiquen, y los scripts utilizados para la obtención de estos datos (si se ha usado alguno). Códigos fuente desarrollados o modificados para la resolución de los ejercicios.

La entrega se realizará a través de moodle, en la fecha indicada para esta entrega.

#### **M**ATERIAL DE REFERENCIA

[1] OpenMP: Tutorials and technical articles <a href="http://openmp.org/wp/resources/#Tutorials">http://openmp.org/wp/resources/#Tutorials</a>